

Bilingual terminology finder on curated non-aligned documents – (prototype)

- UN Digital Library
 - Local documents
-

Communication Division

Social media and web content

- Open-source (available on GitHub)
 - Disclaimer: this app is a personal project not funded nor revised by UNEP staff
-

Nelson Jaimes-Quintero (UNEP)
April 7, Geneva (Switzerland)
JIAMCATT 2025 conference

Bilingual terminology finder on curated non-aligned documents – (prototype)

Plan

1. Objectives
2. Structure
3. Demo

Objectives

TermSeeker tool: github.com/NelsonJQ/termseeker (Python)

Search **candidate terms** in a **non-aligned repository**
for a **given term**.


Tested:

- on **UN Digital Library**. To be adapted to UNEP repository.
- for UN languages (**EN**, **AR**, **ES**, **FR**, **RU**, **ZH**)

Use cases:

- Terminology validation (add sources)
- Add translated terms to a controlled vocabulary
- Multilingual ATE (term extraction)

Structure




Demo

TermSeeker tool:

github.com/NelsonJQ/termseeker

Try it on Google Colab:

https://colab.research.google.com/github/NelsonJQ/termseeker/blob/main/playground_termseeker.ipynb



Output example – ES & FR

	A	B	C	D	E	F	G	H	I	J	K	L
1	English	French	Spanish	French	Spanish	EnglishParagraphs	FrenchParagraphs	SpanishParagraphs	docSymbol	publicationDate	docType	docTitle
	chemical plant	usines chimiques	plantas químicas	['usine chimique']	['planta química']	20. Attacks that damage or destroy extractive mines, chemical plants and oil installations can result in the contamination of land, soil, air and water sources. In turn, this can imperil agriculture and drinking water, cause severe health problems, harm wildlife and biodiversity and contribute to climate change through the release of pollutants and greenhouse gases. In Iraq, air strikes destroyed agricultural land and caused wildfires, including in areas with species at risk of extinction and rich biodiversity. Wildfires along front lines in the north-east of the Syrian Arab Republic have been correlated with media reports of shelling, at times causing secondary fires at oil facilities. In Nigeria, conflict reportedly led to forest fires, loss of wildlife, and land and air pollution. (Source: S/2021/423 on 2021-05-03)	20. Les attaques qui endommagent ou détruisent les exploitations minières, les usines chimiques et les installations pétrolières peuvent entraîner la contamination des terres, du sol, de l'air et des sources d'eau. Cela peut à son tour mettre en péril l'agriculture et l'eau potable, causer de graves problèmes sanitaires, nuire à la vie sauvage et à la biodiversité, et contribuer aux changements climatiques par le rejet de polluants et de gaz à effet de serre. En Iraq, les frappes aériennes ont détruit des terres agricoles et provoqué des incendies de forêt, y compris dans des zones abritant des espèces menacées d'extinction et une riche biodiversité. Les feux de forêt le long des lignes de front dans le nord-est de la République arabe syrienne ont été corrélés avec les bombardements signalés dans les médias, provoquant parfois des incendies secondaires dans les installations pétrolières. Au Nigéria, le conflit aurait entraîné des	20. Los ataques que dañan o destruyen minas extractivas, plantas químicas e instalaciones petroleras pueden contaminar la tierra, los suelos, el aire y las fuentes de agua, lo que a su vez puede poner en peligro la agricultura y el agua potable, causar problemas de salud graves, dañar la vida silvestre y la biodiversidad y contribuir al cambio climático por la emisión de contaminantes y gases de efecto invernadero. En el Iraq, los ataques aéreos destruyeron tierras agrícolas y provocaron incendios forestales, entre otros en zonas donde habitan especies en peligro de extinción y con una rica biodiversidad. Los incendios forestales en las líneas de vanguardia del noreste de la República Árabe Siria se han correlacionado con informes en los medios de comunicación sobre bombardeos de artillería, que en ocasiones han provocado incendios secundarios en instalaciones petroleras. En Nigeria, los informes indican que el conflicto provocó incendios	S/2021/423 S/PV.9069	2021-05-03 2022-06-21	Reports Meeting Records	Protection of civilians in armed conflict : report of the Secretary-General Security Council, 77th year : 9069th meeting, Tuesday, 21 June 2022, New York
2						With the intense fighting in eastern Ukraine, there are increasingly alarming reports of civilian						

Output example – all UN languages

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T
1	English Term	Arabic Term	Chinese Term	French Term	Russian Term	Spanish Term	ArabicS ynony ms	Chinese eSynon yms	French Synony ms	Russian nSynon yms	Spanish hSynon yms	EnglishParagraphs 20. Attacks that damage or destroy extractive mines, chemical plants and oil installations can result in the contamination of land, soil, air and water sources. In turn, this can imperil agriculture and drinking water, cause severe health problems, harm wildlife and biodiversity and contribute to climate change through the release of pollutants and greenhouse gases. In Iraq, air strikes destroyed agricultural land and caused wildfires, including in areas with species at risk of	ArabicParagraphs 20. الت صيرمن اضدر. اللجة الدولية للالليب الأمر ملادئ التويبة المست ملة ب ن امابة 2020 وفي عام - 22 البيئة الطبيعية في للماعا المسلحة. ونحدد هذ الملادا التويبة واعد القا ون الدولي أل ساي المدمول ب ا ايمائتدلق بحماية البيئة الطبيعية ونقدم نوضيا ب — ان اندابير محددة لتندميم الترام القا ون. الدولي أل ساي والحد من ألأر البيئي للمللا المسلسل **استمرار الزواج* (Source: S/2021/423 on 2021-05-03)	ChineseParagraphs 20. 袭击行为造成采掘矿场、化工厂和石油设施遭破坏或被损毁，可能导致土地、土壤、空气和水源被污染。进而也会危及农业和饮用水，造成严重的健康问题，损害野生动植物和生物多样性，并通过释放污染物和温室气体助长气候变化。在伊拉克，空袭摧毁农田，引发野火，包括在有濒临灭绝物种的地区和生物多样性	FrenchParagraphs 20. Les attaques qui endommagent ou détruisent les exploitations minières, les usines chimiques et les installations pétrolières peuvent entraîner la contamination des terres, du sol, de l'air et des sources d'eau. Cela peut à son tour mettre en péril l'agriculture et l'eau potable, causer de graves problèmes sanitaires, nuire à la vie sauvage et à la biodiversité, et contribuer aux changements climatiques par le rejet de polluants et de gaz à effet de serre. En Iraq, les frappes	RussianParagraphs 20. Нападения, в результате которых повреждаются или уничтожаются шахты, химические заводы и нефтяные установки, могут привести к загрязнению земли, почвы, воздуха и источников воды. В свою очередь, это может привести к загрязнению сельскохозяйствен	SpanishParagraphs 20. Los ataques que dañan o destruyen minas extractivas, plantas químicas e instalaciones petroleras pueden contaminar la tierra, los suelos, el aire y las fuentes de agua, lo que a su vez puede poner en peligro la agricultura y el agua potable, causar problemas de salud graves, dañar la vida silvestre y la biodiversidad y contribuir al cambio climático por la emisión de gases de efecto invernadero. En el Iraq, los ataques aéreos destruyeron tierras agrícolas y provocaron incendios	docSymb ol	publicatio nDate	docType
	chemical plant	مصنع كيميائي	化工厂	usines chimiques	химические заводы	plantas químicas	مصنع 'كيميائي', مصنع 'آزوت للكيمياويات'	مصنع 'كيميائي', مصنع 'آزوت للكيمياويات'	مصنع 'كيميائي', مصنع 'آزوت للكيمياويات'	مصنع 'كيميائي', مصنع 'آزوت للكيمياويات'	مصنع 'كيميائي', مصنع 'آزوت للكيمياويات'	مصنع 'كيميائي', مصنع 'آزوت للكيمياويات'	مصنع 'كيميائي', مصنع 'آزوت للكيمياويات'	مصنع 'كيميائي', مصنع 'آزوت للكيمياويات'	مصنع 'كيميائي', مصنع 'آزوت للكيمياويات'	مصنع 'كيميائي', مصنع 'آزوت للكيمياويات'	مصنع 'كيميائي', مصنع 'آزوت للكيمياويات'	S/2021/423 S/PV.9069	2021-05-03 2022-06-21	Reports Meeting Records

Lessons learned and WIP

Nelson Jaimes-Quintero (UNEP)
April 7, Geneva (Switzerland)
JAMCATT 2025 conference




Work in progress

Improvements

- Try Docling instead of pymupdf4llm
- Add a date range filter
- LLM testing (Llama 3.1 7B is not enough, maybe Llama 70B, LlamaX 13b or Alma 13B)

New features

- UNEP repository
- Local TMX or bitexts
- Most similar n-gram as an alternative to LLM querying.



Looking forward

AI Agent-based translation

Resources:

- TMX & bitexts from: UNEP official docs, publications, web topic pages.
- Glossary: extracting and validating terms from our parallel corpora.
- Term finder: TermSeeker
- LLM: small models for translation (NLLB 3B, [X-Alma](#), [LLaMAX3-8B](#))

Implementation strategy:

- ☐ Machine translation with NLLB 600M or 3B.
- ☐ Reflection with LLaMAX3-8B, providing context with:
 - ☐ TMX fuzzy-matches ([Y. Moslem, 2023](#))
 - ☐ Glossary matches ([Andrew Ng, 2024](#))
 - ☐ Proper nouns without glossary entry (TermSeeker).
- ☐ Document-level terminology QA (local glossary).

Asante sana!
Thank you!
¡Gracias!
Merci infiniment !



Nelson Jaimes-Quintero
UNEP digital consultant (NLP specialist)
nelson.jaimesquintero@un.org
nelsonjaimesq@gmail.com (from June)

United Nations Avenue, Gigiri
PO Box 30552 – 00100 GPO Nairobi, Kenya

www.unep.org